Modeli raspodjela vjerovatnoće

izvođenja kroz intuitivne eksperimente

Slučajni signali i procesi – poglavlje 2.4

Sadržaj

Kako koristiti ovaj materijal **2**

1 Osnovni pojmovi i alati **2**

1.1 Funkcija raspodjele i funkcija gustine 2

1.2 Očekivanje i varijansa 3

1.3 Karakteristična funkcija 3

1.4 Transformacija slučajne promjenljive 3

1.5 Metod inverzne transformacije 4

2 Modeli raspodjela vjerovatnoće iz poglavlja 2.4 **4**

2.1 Uniformna raspodjela: bacanje kockice (knjiga 2.4.1) 4

2.2 Gaussova (normalna) raspodjela: Galtonova daska (knjiga 2.4.2) 5

2.3 Rayleigheva raspodjela: pikado (knjiga 2.4.3) 8

2.4 Eksponencijalna raspodjela: radni vijek sijalica (knjiga 2.4.4) 10

3 Pregled za ponavljanje **12**

Kako koristiti ovaj materijal

U knjizi *Slučajni signali i procesi* (poglavlje 2.4) četiri osnovna modela raspodjele vjerovatnoće (uniformna, Gaussova, Rayleigheva i eksponencijalna) data su kao gotove formule, a u programskim kodovima 2.1–2.4 generišu se gotovim funkcijama `np.random.uniform`, `normal`, `rayleigh` i `exponential`. Ovdje je za svaku raspodjelu izabran jedan *fizički eksperiment* u kojem se ona prirodno pojavljuje, a zatim je iz tog eksperimenta izvedena formula iz knjige:

Raspodjela	Eksperiment	Šta se mjeri
Uniformna	bacanje kockice	broj koji padne (sve je jednako vjerovatno)
Gaussova	Galtonova daska	položaj kuglice nakon mnogo skretanja lijevo/desno
Rayleigheva	pikado (primjer iz knjige)	udaljenost pogotka od centra mete
Eksponencijalna	sijalice („radni vijek uređaja“)	koliko sati sijalica radi do kvara

Za svaku raspodjelu postoji Python bilježnica za Google Colab u istom folderu:

- `R1_Uniformna_raspodjela.ipynb`,
- `R2_Gaussova_raspodjela.ipynb`,
- `R3_Rayleigheva_raspodjela.ipynb`,
- `R4_Eksponencijalna_raspodjela.ipynb`.

Bilježnica se otvori u Colabu (*File* → *Upload notebook*) i pokrene sa *Runtime* → *Run all*. Prva ćelija sama klonira repozitorij `github.com/esokic/ssp` i učita biblioteku `ssp` koja prati knjigu, tačno po uputstvu iz README-a. Svaka bilježnica radi $N = 10\,000$ eksperimenata. Rezultati se prikazuju funkcijama iz knjige `ssp.slprom1D.realizacije`, `PDF`, `pdf` i `grafik`, a porede se sa teoretskom krivom i sa generatorom iz odgovarajućeg programskog koda.

Iz knjige i sa GitHuba su iskorišteni:

- izračunavanje očekivanja i varijanse za sve četiri raspodjele (poglavlje 2.5.4, relacije 2.25–2.47);
- kod 2.5 (kockica), zadatak „Alma i Sara“ iz poglavlja 3 (primjena uniformne raspodjele);
- centralna granična teorema (poglavlje 3.5, kod 3.2), na kojoj počiva Galtonova daska;
- Primjer 2.15 i kodovi 2.44–2.47 (Box–Mullerova transformacija), veza Rayleigheve i Gaussove raspodjele;
- Primjer 2.13 i kod 2.41 ($Y = -\frac{1}{\lambda}\ln(1-X)$), dobijanje eksponencijalne iz uniformne.

Svako poglavlje ima isti raspored. Prvo ide kratka *ideja*, zatim opis *eksperimenta* iz bilježnice, pa *izvođenje* $p(x)$ i $P(x)$ i na kraju provjera očekivanja i varijanse, uz slike jednog pokretanja bilježnice. Kod tebe će brojevi biti malo drugačiji, jer je eksperiment slučajan, ali slaganje sa teorijom mora biti isto ovako dobro. Plave oznake tipa (knjiga 2.8) upućuju na relacije u knjizi.

Preporuka za učenje: prvo dobro savladaj poglavlje 1 (alati), jer se sva kasnija izvođenja svode na tri ista trika: funkciju raspodjele, karakterističnu funkciju i granični prelaz.

1 Osnovni pojmovi i alati

1.1 Funkcija raspodjele i funkcija gustine

Iz knjige (knjiga 2.1–2.4):

$$P_X(x) = \text{vjerovatnoća}(X \le x), \qquad p_X(x) = \frac{\mathrm{d}P_X(x)}{\mathrm{d}x}, \qquad P_X(x) = \int_{-\infty}^{x} p_X(t)\,\mathrm{d}t,$$

uz $p_X(x) \ge 0$, $\int_{-\infty}^{\infty} p_X(x)\,\mathrm{d}x = 1$ i $\int_a^b p_X(x)\,\mathrm{d}x = P(b) - P(a)$. Za diskretnu promjenljivu koristi se funkcija vjerovatnoće (PMF) $p_X(k) = \text{vjerovatnoća}(X = k)$, a funkcija raspodjele je stepenasta:

$P_X(x) = \sum_{k \le x} p_X(k)$.

Zapamti

Gotovo svako izvođenje u ovom dokumentu ide po istom receptu: **(1)** opiše se kako nova promjenljiva nastaje iz kockice, **(2)** izračuna se $P(x) = \text{vjerovatnoća}(X \le x)$ direktno iz tog opisa, **(3)** izvod daje $p(x)$. Raditi preko $P(x)$ je lakše nego direktno preko $p(x)$, jer je $P(x)$ obična vjerovatnoća pa se može *prebrojati* ili izračunati logikom događaja.

1.2 Očekivanje i varijansa

Iz knjige (knjiga 2.18–2.20):

$$\mathrm{E}[f(X)] = \int_{-\infty}^{\infty} f(x)p(x)\,\mathrm{d}x, \qquad \mathrm{E}[X] = \int x\,p(x)\,\mathrm{d}x, \qquad \mathrm{Var}[X] = \mathrm{E}[X^2] - (\mathrm{E}[X])^2.$$

Linearnost (knjiga 2.19): $\mathrm{E}[c_1X_1 + c_2X_2] = c_1\mathrm{E}[X_1] + c_2\mathrm{E}[X_2]$ vrijedi *uvijek*. Za *nezavisne* promjenljive vrijedi još i $\mathrm{Var}[X_1 + X_2] = \mathrm{Var}[X_1] + \mathrm{Var}[X_2]$.

1.3 Karakteristična funkcija

Iz knjige (knjiga 2.5):

$$\Phi_X(u) = \mathrm{E}\big[e^{juX}\big] = \int_{-\infty}^{\infty} p_X(x)e^{jux}\,\mathrm{d}x.$$

Dva svojstva čine je izuzetno korisnom:

(a) **Jednoznačnost.** Ako dvije promjenljive imaju istu karakterističnu funkciju, imaju i istu raspodjelu (to je Fourierova transformacija, a ona ima inverz). Zato je za dokaz da X ima neku raspodjelu dovoljno pokazati da mu je karakteristična funkcija jednaka karakterističnoj funkciji te raspodjele.

(b) **Zbir nezavisnih promjenljivih postaje proizvod.** Ako su X i Y nezavisne:

$$\Phi_{X+Y}(u) = \mathrm{E}\big[e^{ju(X+Y)}\big] = \mathrm{E}\big[e^{juX}\big]\,\mathrm{E}\big[e^{juY}\big] = \Phi_X(u)\,\Phi_Y(u).$$

Gustina zbira je konvolucija gustina, $p_{X+Y} = p_X * p_Y$, a Fourierova transformacija konvoluciju pretvara u proizvod, pa je ovo isto pravilo zapisano u frekvencijskom domenu.

1.4 Transformacija slučajne promjenljive

Ako je $Y = g(X)$ i g je rastuća funkcija, onda je

$$P_Y(y) = \text{vjer.}(g(X) \le y) = \text{vjer.}(X \le g^{-1}(y)) = P_X(g^{-1}(y)), \qquad p_Y(y) = p_X\big(g^{-1}(y)\big)\left|\frac{\mathrm{d}g^{-1}(y)}{\mathrm{d}y}\right|.$$

Za opadajuću g dobija se isti izraz za p_Y (zato apsolutna vrijednost). Specijalno, za linearnu transformaciju $Y = a + \sigma X$ $(\sigma > 0)$:

$$P_Y(y) = P_X\Big(\frac{y-a}{\sigma}\Big), \qquad p_Y(y) = \frac{1}{\sigma}\,p_X\Big(\frac{y-a}{\sigma}\Big).$$

1.5 Metod inverzne transformacije

Tvrdnja. Neka je U uniformna na $(0,1)$ i neka je $P(x)$ neka rastuća funkcija raspodjele. Tada promjenljiva $X = P^{-1}(U)$ ima funkciju raspodjele baš $P(x)$.

Dokaz. vjer.$(X \le x)$ = vjer.$(P^{-1}(U) \le x)$ = vjer.$(U \le P(x))$ = $P(x)$, jer je za uniformnu U vjerovatnoća vjer.$(U \le t) = t$.

Zbog ovoga knjiga kaže da je uniformna raspodjela *„značajna jer se uz pomoć nje mogu formirati ostale raspodjele“*. Knjiga to koristi u Primjeru 2.13 (eksponencijalna iz uniformne) i Primjeru 2.15 (Gaussova iz dvije uniformne).

2 Modeli raspodjela vjerovatnoće iz poglavlja 2.4

2.1 Uniformna raspodjela: bacanje kockice (knjiga 2.4.1)

$$p(x) = \begin{cases} \dfrac{1}{b-a}, & a \le x \le b \\ 0, & \text{inače} \end{cases} \qquad P(x) = \begin{cases} 0, & x < a \\ \dfrac{x-a}{b-a}, & a \le x \le b \\ 1, & x > b \end{cases} \qquad \text{(knjiga 2.6, 2.7)}$$

Ideja

Uniformna raspodjela opisuje situaciju u kojoj *nijedan ishod nema prednost*. Kod poštene kockice svaki broj pada sa vjerovatnoćom 1/6 (slike 2.3–2.5 u knjizi). Knjiga kaže da se uniformna raspodjela koristi kada „ne postoje apriori informacije“ o promjenljivoj, a to je upravo slučaj kockice: nemamo razloga da očekujemo jedan broj više od drugog.

Eksperiment – `R1_Uniformna_raspodjela.ipynb`

1. 10 000 bacanja obične kockice (kod 2.5): frekvencije brojeva i funkcija raspodjele.
2. „Kockica sa n strana“ za $n = 6, 20, 100, 10\,000$, pri čemu se broj k pretvori u tačku $X = a + (b-a)\frac{k-1/2}{n}$ na $[a,b] = [0,10]$. Kako n raste, stepenice postaju prava linija (2.7). Rezultat se poredi sa `np.random.uniform(a, b, N)` iz koda 2.1.
3. Primjena: zadatak „Alma i Sara“ (dolazak u slučajnom trenutku između 14 i 15 h).

Diskretna uniformna raspodjela (kockica sa n strana). Svaki od n ishoda ima vjerovatnoću $1/n$. Očekivanje i varijansa:

$$\mathrm{E}[D] = \frac{1}{n}\sum_{k=1}^{n} k = \frac{n+1}{2}, \qquad \mathrm{E}[D^2] = \frac{1}{n}\sum_{k=1}^{n} k^2 = \frac{(n+1)(2n+1)}{6},$$

$$\mathrm{Var}[D] = \frac{(n+1)(2n+1)}{6} - \frac{(n+1)^2}{4} = \frac{(n+1)(4n+2-3n-3)}{12} = \frac{n^2-1}{12}.$$

Za običnu kockicu ($n = 6$): $\mathrm{E}[D] = 3{,}5$ i $\mathrm{Var}[D] = 35/12 \approx 2{,}917$. Bilježnica je dala 3,518 i 2,970, a relativne frekvencije brojeva 1–6 bile su između 0,163 i 0,175.

Od diskretne ka kontinualnoj. Kockica sa n strana dijeli interval $[a,b]$ na n jednakih dijelova dužine $\Delta = \frac{b-a}{n}$, a svaka strana „pokriva“ jedan dio, sa vjerovatnoćom $\frac{1}{n}$. Zato je vjerovatnoća bilo kojeg podintervala proporcionalna njegovoj dužini:

$$\text{vjer.}(x_1 < X \le x_2) \approx \frac{\text{broj strana u } (x_1, x_2]}{n} \approx \frac{(x_2 - x_1)/\Delta}{n} = \frac{x_2 - x_1}{b-a}.$$

Greška ove aproksimacije je najviše jedna strana, tj. $\frac{1}{n}$, i nestaje za $n \to \infty$. Uzimanjem $x_1 = a$ i $x_2 = x$ dobija se

$$P(x) = \text{vjer.}(X \le x) = \frac{x-a}{b-a}, \qquad p(x) = \frac{\mathrm{d}P}{\mathrm{d}x} = \frac{1}{b-a}, \qquad a \le x \le b,$$

a to su tačno relacije (knjiga 2.6) i (knjiga 2.7). Upravo to pokazuje slika 1: za $n = 6$ funkcija raspodjele ima 6 stepenica visine $1/6$, za $n = 20$ ima 20 sitnijih, a za $n = 100$ se stepenice više ne vide. I varijansa prelazi u kontinualnu formulu. Za $X = a + \Delta\,(D - \frac{1}{2})$ je

$$\mathrm{Var}[X] = \Delta^2\,\frac{n^2-1}{12} = \frac{(b-a)^2}{12}\Big(1 - \frac{1}{n^2}\Big) \xrightarrow{n\to\infty} \frac{(b-a)^2}{12}.$$

Očekivanje i varijansa direktno (knjiga 2.25–2.27).

$$\mathrm{E}[X] = \int_a^b \frac{x}{b-a}\,\mathrm{d}x = \frac{b^2-a^2}{2(b-a)} = \frac{a+b}{2}, \qquad \mathrm{E}[X^2] = \int_a^b \frac{x^2}{b-a}\,\mathrm{d}x = \frac{a^2+ab+b^2}{3},$$

$$\mathrm{Var}[X] = \frac{a^2+ab+b^2}{3} - \frac{(a+b)^2}{4} = \frac{(b-a)^2}{12}.$$

Za $a = 0$, $b = 10$: $\mathrm{E}[X] = 5$ i $\mathrm{Var}[X] = 8{,}333$. Bilježnica je za kockicu sa 10 000 strana dala 4,962 i 8,214. Očekivanje se može dobiti i bez integrala: $p(x)$ je simetrična oko $\frac{a+b}{2}$, pa je to i očekivanje (Primjer 2.1 u knjizi).

Primjena: Alma i Sara. Neka su dolasci A i S (u minutama nakon 14 h) nezavisni i uniformni na $[0, 60]$. Zajednička gustina je tada konstantna, $\frac{1}{60} \cdot \frac{1}{60}$, na kvadratu 60×60, pa je vjerovatnoća bilo kojeg događaja jednaka *površini* tog dijela kvadrata podijeljenoj sa 3600. Sretnu se ako je $|A - S| \le 20$. Nepovoljna su dva ugaona trougla sa katetama 40, ukupne površine $2 \cdot \frac{40^2}{2} = 1600$:

$$\text{vjer.}(|A-S| \le 20) = \frac{3600 - 1600}{3600} = \frac{5}{9} \approx 0{,}556.$$

Simulacija u bilježnici je dala 0,553.

2.2 Gaussova (normalna) raspodjela: Galtonova daska (knjiga 2.4.2)

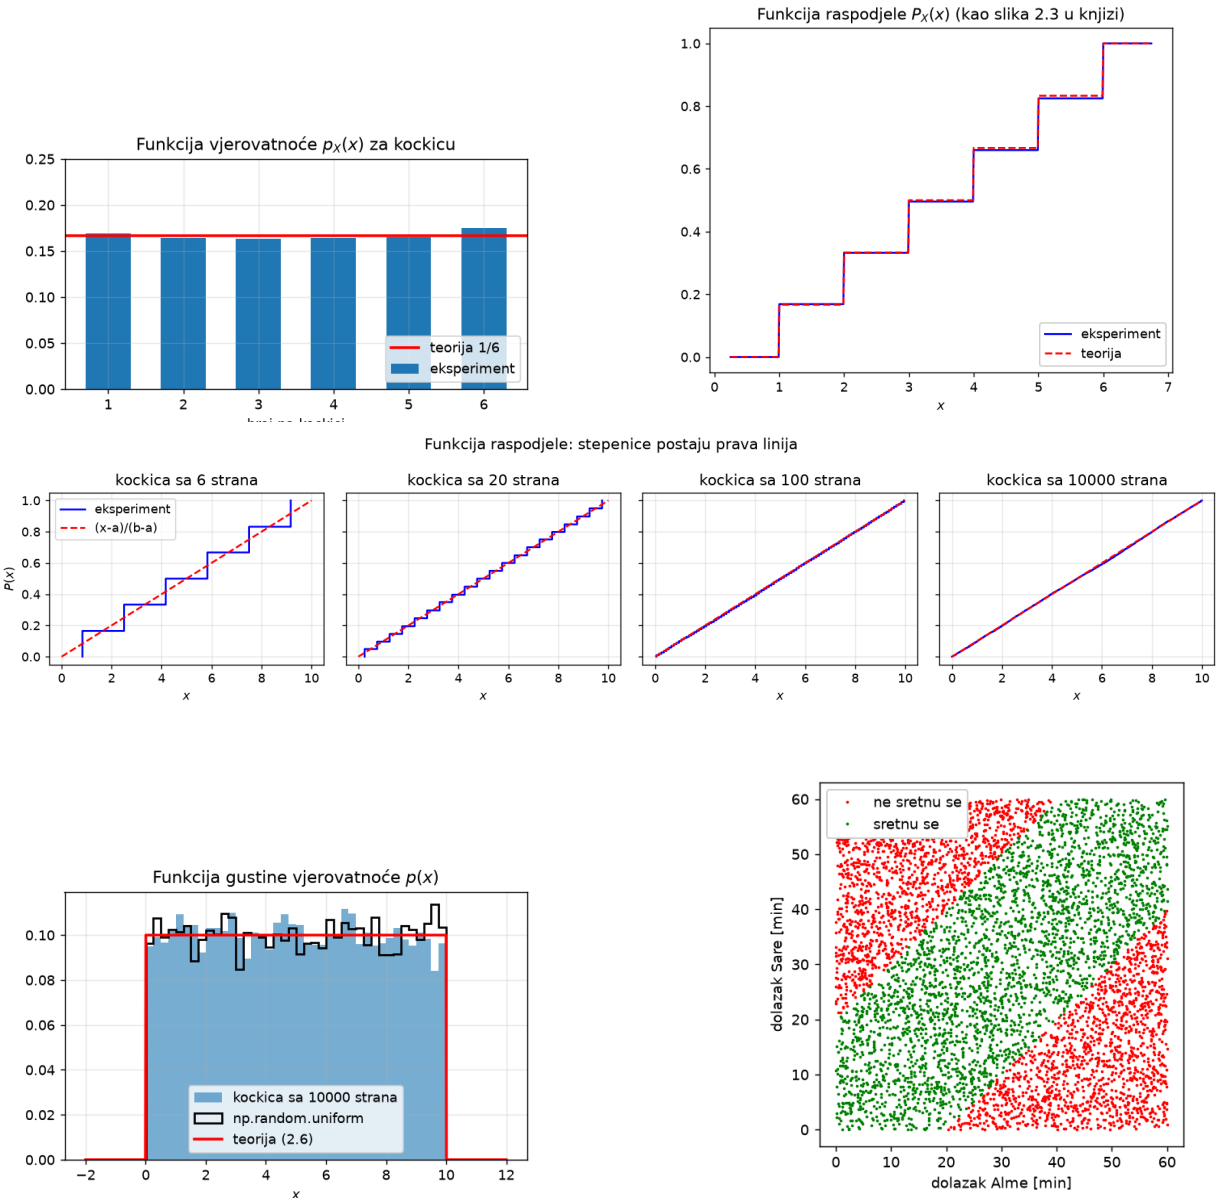
$$p(x) = \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}}, \qquad P(x) = \Phi\Big(\frac{x-a}{\sigma}\Big) = \frac{1}{2}\Big[1 + \mathrm{erf}\Big(\frac{x-a}{\sqrt{2}\,\sigma}\Big)\Big] \qquad \text{(knjiga 2.12, 2.13)}$$

Ideja

Galtonova daska je kosa daska sa R redova klinova. Kuglica pada odozgo i na svakom klinu skrene lijevo ili desno, svaki put sa vjerovatnoćom $\frac{1}{2}$. Na dnu se kuglice skupljaju u pregrade i same „nacrtaju“ Gaussovo zvono. Konačni položaj je *zbir mnogo malih nezavisnih uticaja*, a to je po centralnoj graničnoj teoremi (poglavlje 3.5 knjige) uvijek približno Gaussovo. Isto vrijedi za visinu ljudi, greške mjerenja i šum, zbog čega knjiga kaže da Gaussova raspodjela modelira „jako veliki broj prirodnih fenomena“.

Eksperiment – `R2_Gaussova_raspodjela.ipynb`

Skretanje na jednom klinu je $Y_i = \pm 1$, a položaj nakon R redova je $X = Y_1 + \cdots + Y_R$. Bilježnica crta dasku sa putanjama nekoliko kuglica, pa pušta 10 000 kuglica za $R = 2, 5, 12, 50$ i poredi standardizovani položaj $X/\sqrt{R}$ sa $\mathcal{N}(0, 1)$. Za $R = 50$ se poredi i sa `np.random.normal` iz koda 2.2.



Slika 1: Uniformna raspodjela: obična kockica (gore), kockica sa sve više strana (sredina), gustina za $n = 10\,000$ u poređenju sa `np.random.uniform` i zadatak „Alma i Sara“ (dolje).

Korak 1: tačna raspodjela (prebrojavanje putanja). Neka je K broj skretanja udesno. Tada je $X = K - (R - K) = 2K - R$. Svaka putanja kroz dasku je niz od R odluka lijevo/desno i ima vjerovatnoću $\left(\frac{1}{2}\right)^R$. Putanja sa tačno k skretanja udesno ima $\binom{R}{k}$ (biramo u kojim redovima kuglica ide desno), pa je

$$\text{vjer.}(K = k) = \binom{R}{k} \frac{1}{2^R}, \qquad k = 0, 1, \ldots, R.$$

To je binomijalna raspodjela (tabela 2.2), a brojevi $\binom{R}{k}$ su redovi Pascalovog trougla. Zato je u srednje pregrade moguće stići na mnogo više načina nego u krajnje (u krajnju lijevu samo na jedan, „uvijek lijevo“).

Korak 2: očekivanje i varijansa. Za jedno skretanje je $\mathrm{E}[Y] = \frac{1}{2}(+1) + \frac{1}{2}(-1) = 0$ i $\mathrm{E}[Y^2] = 1$, pa je $\mathrm{Var}[Y] = 1$. Skretanja su nezavisna, pa iz linearnosti (knjiga 2.19) slijedi

$$\mathrm{E}[X] = 0, \qquad \mathrm{Var}[X] = R \cdot \mathrm{Var}[Y] = R.$$

Rasipanje raste kao $\sqrt{R}$, pa je prirodno posmatrati standardizovani položaj $Z_R = X/\sqrt{R}$, koji ima očekivanje 0 i varijansu 1 za svako R.

Korak 3: karakteristična funkcija. Za jedno skretanje:

$$\Phi_Y(u) = \mathrm{E}[e^{juY}] = \tfrac{1}{2}e^{ju} + \tfrac{1}{2}e^{-ju} = \cos u.$$

Skretanja su nezavisna, pa se karakteristične funkcije množe (svojstvo (b) iz poglavlja 1.3):

$$\Phi_{Z_R}(u) = \Big[\cos\frac{u}{\sqrt{R}}\Big]^R.$$

Za malo v je $\cos v = 1 - \frac{v^2}{2} + \ldots$, pa je

$$\Phi_{Z_R}(u) = \Big[1 - \frac{u^2}{2R} + \ldots\Big]^R \xrightarrow{R\to\infty} e^{-u^2/2},$$

po poznatom limesu $(1 + x/R)^R \to e^x$. Od raspodjele jednog skretanja ostali su samo $\mathrm{E}[Y] = 0$ i $\mathrm{E}[Y^2] = 1$, a sve ostalo nestaje u višim članovima razvoja. Zato centralna granična teorema vrijedi za bilo kakve sabirke sa konačnom varijansom, u obliku (knjiga 3.21): $\frac{1}{\sqrt{n}}\sum \frac{X_i - \mu}{\sigma} \to \mathcal{N}(0,1)$. Kod 3.2 to pokazuje na Rayleighevim sabircima.

Korak 4: koja gustina ima karakterističnu funkciju $e^{-u^2/2}$? Pokažimo da je to $\varphi(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ iz (knjiga 2.8). Dopunom do punog kvadrata, $-\frac{x^2}{2} + jux = -\frac{(x-ju)^2}{2} - \frac{u^2}{2}$, pa je

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} e^{jux}\,\mathrm{d}x = e^{-u^2/2} \underbrace{\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-(x-ju)^2/2}\,\mathrm{d}x}_{=1} = e^{-u^2/2}.$$

(Pomjeranje integracione prave za ju ne mijenja integral jer je podintegralna funkcija analitička i brzo opada.) Po jednoznačnosti karakteristične funkcije zaključujemo da **standardizovani položaj kuglice teži standardnoj normalnoj raspodjeli**.

Zašto baš $\sqrt{2\pi}$? (normiranost) Neka je $I = \int_{-\infty}^{\infty} e^{-x^2/2}\,\mathrm{d}x$. Tada je, prelaskom u polarne koordinate ($x = r\cos\theta$, $y = r\sin\theta$, $\mathrm{d}x\,\mathrm{d}y = r\,\mathrm{d}r\,\mathrm{d}\theta$):

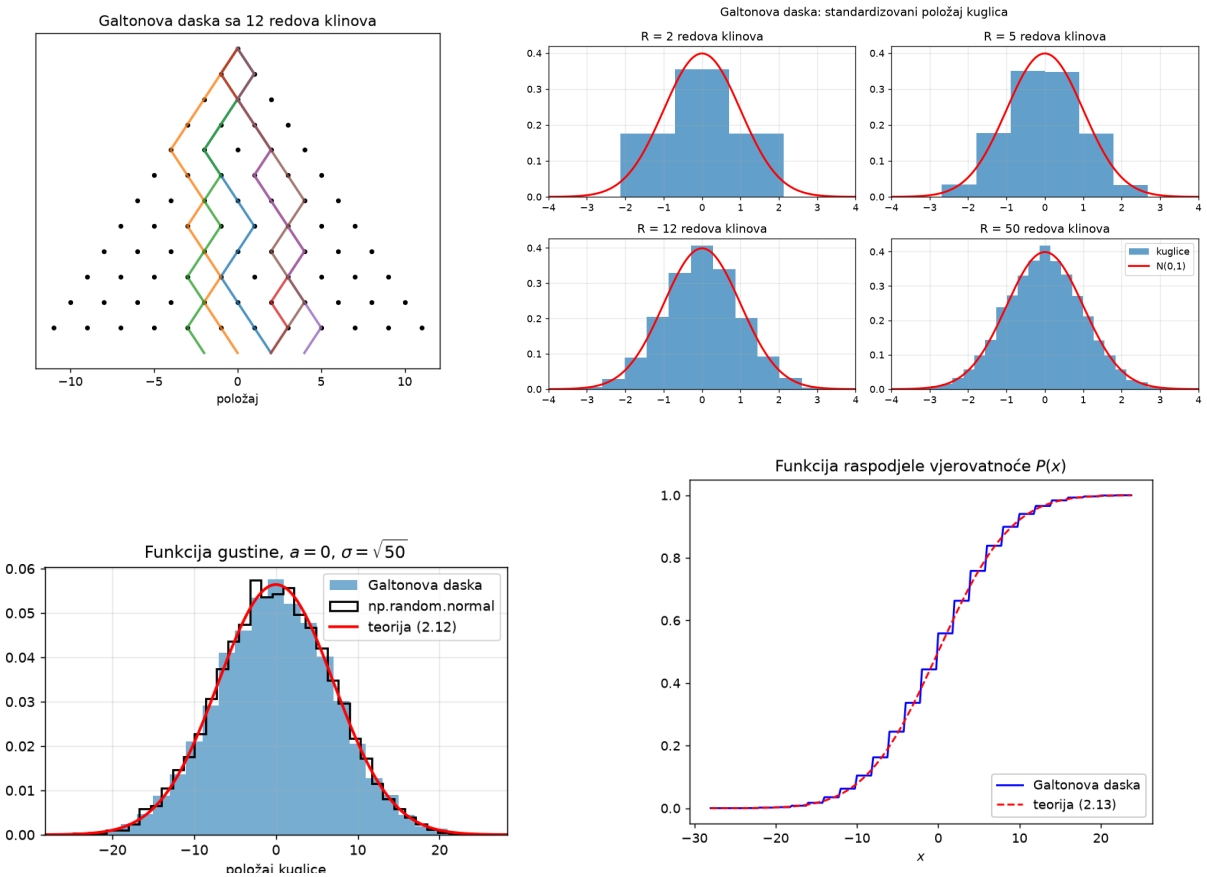
$$I^2 = \iint e^{-\frac{x^2+y^2}{2}}\,\mathrm{d}x\,\mathrm{d}y = \int_0^{2\pi}\int_0^{\infty} e^{-r^2/2}\,r\,\mathrm{d}r\,\mathrm{d}\theta = 2\pi\Big[-e^{-r^2/2}\Big]_0^{\infty} = 2\pi,$$

dakle $I = \sqrt{2\pi}$ i $\int \varphi(x)\,\mathrm{d}x = 1$. Isti trik je osnova Rayleigheve raspodjele.

Korak 5: opšti oblik i erf**.** Za $X = a + \sigma Z$ linearna transformacija (poglavlje 1.4) daje tačno (knjiga 2.12): $p(x) = \frac{1}{\sigma}\varphi(\frac{x-a}{\sigma})$. Za Galtonovu dasku je $a = 0$ i $\sigma = \sqrt{R}$. Knjiga u (knjiga 2.28–2.37) integracijom pokazuje da su $\mathrm{E}[X] = a$ i $\mathrm{Var}[X] = \sigma^2$, što se slaže sa Korakom 2. Veza sa funkcijom greške (knjiga 2.10, 2.11) dobija se smjenom $t = \sqrt{2}\,s$:

$$\Phi(x) = \frac{1}{2} + \frac{1}{\sqrt{2\pi}}\int_0^x e^{-t^2/2}\,\mathrm{d}t = \frac{1}{2} + \frac{1}{\sqrt{\pi}}\int_0^{x/\sqrt{2}} e^{-s^2}\,\mathrm{d}s = \frac{1}{2}\Big[1 + \mathrm{erf}\Big(\frac{x}{\sqrt{2}}\Big)\Big].$$

Rezultat bilježnice. Za $R = 50$: $\mathrm{E}[X] = -0{,}029$ (teorija 0), $\mathrm{Var}[X] = 50{,}69$ (teorija 50). U intervalu $\pm 3\sigma$ je bilo 99,74% kuglica (teorija 99,73%). U intervalu $\pm 2\sigma$ bilo je 96,6%, a ne 95,4%, jer kuglica može završiti samo u pregradama $0, \pm 2, \pm 4, \ldots$. Granica $2\sigma \approx 14{,}1$ zato obuhvati cijele pregrade ± 14, a tačna binomijalna vjerovatnoća tog događaja je 0,967. Sa više redova klinova ta razlika nestaje.



Slika 2: Galtonova daska: putanje kuglica, oblik raspodjele za $R = 2, 5, 12, 50$ redova i poređenje sa teorijom i sa `np.random.normal` za $R = 50$.

2.3 Rayleigheva raspodjela: pikado (knjiga 2.4.3)

$$p(x) = \frac{x}{\sigma^2} e^{-\frac{1}{2}\left(\frac{x}{\sigma}\right)^2}, \qquad P(x) = 1 - e^{-\frac{1}{2}\left(\frac{x}{\sigma}\right)^2}, \qquad x \geq 0 \qquad \text{(knjiga 2.14, 2.15)}$$

Ideja

Knjiga sama navodi primjer „gađanja u metu strelicama pikada“. Igrač gađa centar, ali mu ruka malo „drhti“ u oba smjera: greška po horizontali X i greška po vertikali Y su nezavisne Gaussove promjenljive $\mathcal{N}(0, \sigma^2)$. Rayleigheva raspodjela opisuje *udaljenost* pogotka od centra, $R = \sqrt{X^2 + Y^2}$. Parametar σ je „preciznost“ igrača: dobar igrač ima malo σ.

Eksperiment – `R3_Rayleigheva_raspodjela.ipynb`

Prvo se nacrtaju mete dva igrača ($\sigma = 2$ i $\sigma = 5$, kao na slici 2.9 u knjizi gdje je $\sigma_1 < \sigma_2$). Zatim igrač sa $\sigma = 5$ baci 10 000 strelica (kao $\eta = 5$ u kodu 2.3) i mjeri se $R = \sqrt{X^2 + Y^2}$. Rezultat se poredi sa `np.random.rayleigh(5, N)`, a gustina se procjenjuje i funkcijom `ssp.slprom1D.pdf`.

Izvođenje preko $P(r)$. Zajednička gustina nezavisnih X i Y je proizvod gustina:

$$p(x,y) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{y^2}{2\sigma^2}} = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}.$$

Ova funkcija zavisi samo od x^2+y^2, tj. ima kružnu simetriju, kao i meta. Događaj $R \le r$ znači da je strelica unutar kruga poluprečnika r, pa je

$$P(r) = \text{vjer.}(R \le r) = \iint_{x^2+y^2 \le r^2} \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \,\mathrm{d}x\,\mathrm{d}y.$$

U polarnim koordinatama ($\mathrm{d}x\,\mathrm{d}y = \rho\,\mathrm{d}\rho\,\mathrm{d}\theta$):

$$P(r) = \int_0^{2\pi}\int_0^{r} \frac{1}{2\pi\sigma^2} e^{-\frac{\rho^2}{2\sigma^2}} \rho\,\mathrm{d}\rho\,\mathrm{d}\theta = \int_0^{r} \frac{\rho}{\sigma^2} e^{-\frac{\rho^2}{2\sigma^2}}\,\mathrm{d}\rho = \Big[-e^{-\frac{\rho^2}{2\sigma^2}}\Big]_0^{r} = 1 - e^{-\frac{r^2}{2\sigma^2}},$$

što je (knjiga 2.15). Izvod po r daje (knjiga 2.14): $p(r) = \frac{r}{\sigma^2} e^{-r^2/(2\sigma^2)}$.

Zašto je $p(0)=0$ iako je centar „najgušći“? Faktor r ispred eksponencijalne funkcije dolazi od $\rho\,\mathrm{d}\rho$: prsten poluprečnika r i širine $\mathrm{d}r$ ima površinu $2\pi r\,\mathrm{d}r$, pa na većim udaljenostima ima „više mjesta“ za pogodak. Gustina pogodaka po jedinici površine je najveća u centru, ali je sam centar mali. Najvjerovatnija udaljenost (modalna tačka, poglavlje 2.5.5) dobija se iz $p'(r)=0$:

$$\frac{\mathrm{d}}{\mathrm{d}r}\Big(r e^{-\frac{r^2}{2\sigma^2}}\Big) = \Big(1 - \frac{r^2}{\sigma^2}\Big) e^{-\frac{r^2}{2\sigma^2}} = 0 \quad\Rightarrow\quad r = \sigma.$$

Medijan iz $P(m) = \frac{1}{2}$ (knjiga 2.48): $e^{-m^2/(2\sigma^2)} = \frac{1}{2}$, pa je $m = \sigma\sqrt{2\ln 2} \approx 1{,}177\sigma$. Usput se iz integrala vidi i da je ugao θ uniforman na $[0, 2\pi)$, jer u integralu po θ nema ničega.

Veza sa Primjerom 2.15 (Box–Muller). U Primjeru 2.15 knjiga polazi od dvije uniformne X, Y i pokazuje da tačka $Z = \sqrt{-2\ln X}\cos(2\pi Y)$, $W = \sqrt{-2\ln X}\sin(2\pi Y)$ ima dvodimenzionalnu Gaussovu raspodjelu. To je naše izvođenje „unazad“: poluprečnik te tačke je $\sqrt{-2\ln X}$, a

$$\text{vjer.}(\sqrt{-2\ln X} \le r) = \text{vjer.}(X \ge e^{-r^2/2}) = 1 - e^{-r^2/2},$$

što je Rayleigheva raspodjela sa $\sigma = 1$. Ugao $2\pi Y$ je uniforman, kao što smo i dobili.

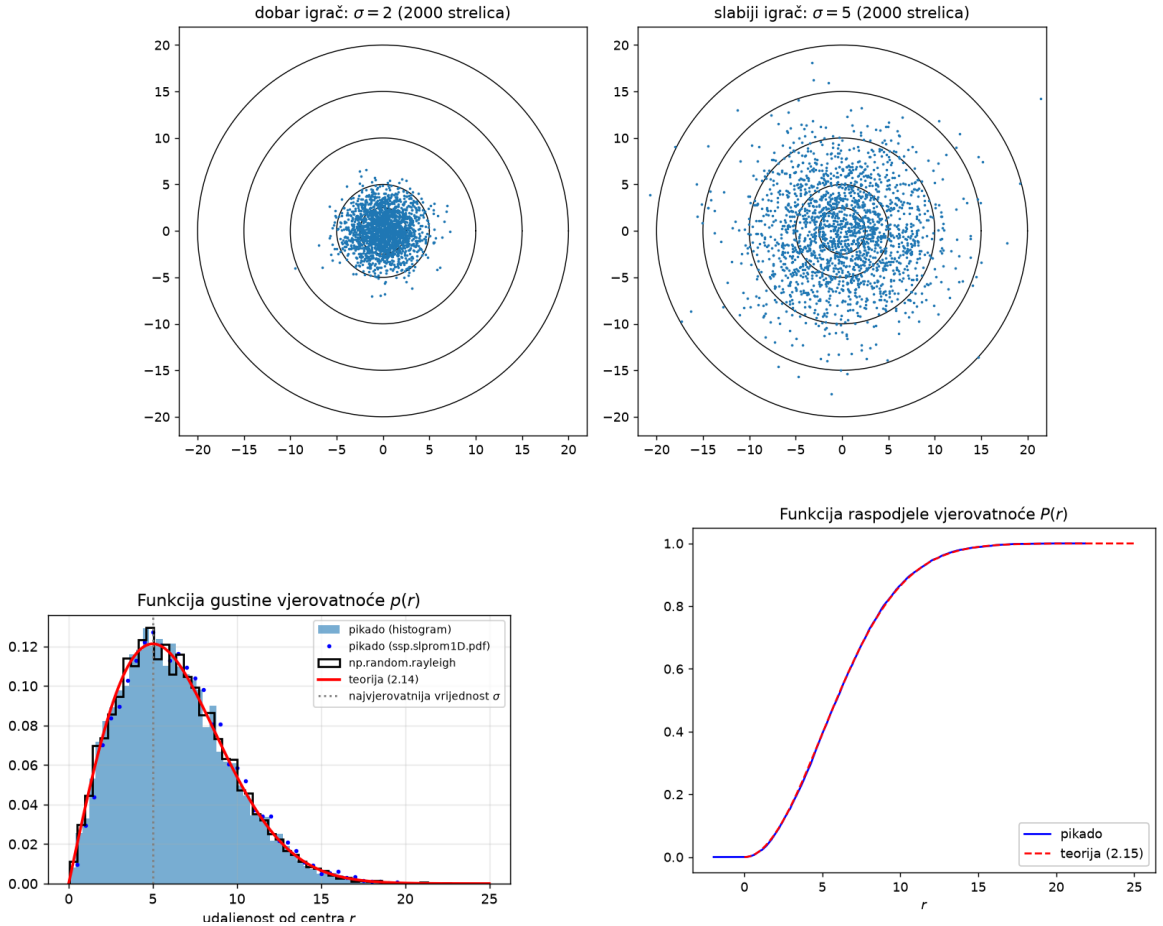
Očekivanje i varijansa (knjiga 2.38–2.42). $\mathrm{E}[R^2] = \mathrm{E}[X^2] + \mathrm{E}[Y^2] = 2\sigma^2$, bez ikakvog integrala. Za očekivanje knjiga koristi parcijalnu integraciju i svođenje na Gaussov integral

$$\int_0^{\infty} e^{-r^2/(2\sigma^2)}\,\mathrm{d}r = \frac{1}{2}\sqrt{2\pi}\,\sigma,$$

pa je

$$\mathrm{E}[R] = \int_0^{\infty} \frac{r^2}{\sigma^2} e^{-\frac{r^2}{2\sigma^2}}\,\mathrm{d}r = \sigma\sqrt{\frac{\pi}{2}}, \qquad \mathrm{Var}[R] = 2\sigma^2 - \frac{\pi}{2}\sigma^2 = \frac{4-\pi}{2}\sigma^2.$$

Za $\sigma = 5$ teorija daje $\mathrm{E}[R] = 6{,}267$, $\mathrm{Var}[R] = 10{,}73$ i medijan $5{,}887$, a bilježnica $6{,}274$, $10{,}55$ i $5{,}918$. Iz (knjiga 2.15) se direktno čita i koliko strelica ulazi u krug: u krug poluprečnika σ ulazi $1 - e^{-1/2} = 39{,}3\%$ (bilježnica 39,3%), u 2σ ulazi 86,5% (bilježnica 86,7%), a u 3σ ulazi 98,9% (bilježnica 98,8%).



Slika 3: Pikado: mete dobrog ($\sigma = 2$) i slabijeg ($\sigma = 5$) igrača, gustina i funkcija raspodjele udaljenosti od centra za $\sigma = 5$.

2.4 Eksponencijalna raspodjela: radni vijek sijalica (knjiga 2.4.4)

$$p(x) = ae^{-ax}, \qquad P(x) = 1 - e^{-ax}, \qquad x \geq 0 \qquad \text{(knjiga 2.16, 2.17)}$$

Ideja

Knjiga kaže da se eksponencijalnom raspodjelom modeliraju „problemi kašnjenja i radni vijek uređaja“. Uključimo mnogo sijalica. Ispravna sijalica u svakom satu može pregorjeti sa malom vjerovatnoćom p, i to *nezavisno od toga koliko je već radila*: ne troši se, nego je kvar uvijek jednako vjerovatan (npr. zbog naponskog udara). Vrijeme do kvara tada ima eksponencijalnu raspodjelu. Ista matematika opisuje radioaktivni raspad i vrijeme čekanja na sljedeći poziv u call-centru.

Eksperiment – `R4_Eksponencijalna_raspodjela.ipynb`

10 000 sijalica; svaka ispravna pregori u toku sata sa vjerovatnoćom $p = 0{,}01$. Bilježi se radni vijek svake sijalice i broj sijalica koje još rade nakon t sati. Rezultat se poredi sa `np.random.exponential` (kod 2.4) i sa $-\frac{1}{a}\ln(1-X)$ (Primjer 2.13, kod 2.41), a na kraju se provjerava da „stara sijalica nije lošija od nove“.

Pažnja kod koda 2.4: argument funkcije `np.random.exponential` je *skala*, odnosno srednja vrijednost $1/a$, a ne a iz relacije (knjiga 2.16). Poziv `np.random.exponential(4, N)` zato odgovara $a = 1/4$.

Izvođenje 1: koliko sijalica još radi (diferencijalna jednačina). Neka je $N(t)$ broj ispravnih sijalica u trenutku t. U kratkom intervalu $\mathrm{d}t$ svaka ispravna sijalica pregori sa vjerovatnoćom $a\,\mathrm{d}t$, pa očekivani broj kvarova iznosi $a\,N(t)\,\mathrm{d}t$:

$$\mathrm{d}N = -a\,N(t)\,\mathrm{d}t \quad\Rightarrow\quad \frac{\mathrm{d}N}{N} = -a\,\mathrm{d}t \quad\Rightarrow\quad N(t) = N_0 e^{-at}.$$

Što više sijalica radi, više ih i pregori, pa broj ispravnih pada eksponencijalno, kao kod radioaktivnog raspada. Udio sijalica koje rade duže od t je vjerovatnoća da slučajno izabrana sijalica radi duže od t:

$$\text{vjer.}(T > t) = \frac{N(t)}{N_0} = e^{-at} \quad\Rightarrow\quad P(t) = 1 - e^{-at}, \qquad p(t) = \frac{\mathrm{d}P}{\mathrm{d}t} = ae^{-at},$$

a to su (knjiga 2.16) i (knjiga 2.17).

Izvođenje 2: iz pravila eksperimenta (granični prelaz). Da bi sijalica radila duže od t sati, mora „preživjeti“ svaki od tih t sati, a sati su nezavisni:

$$\text{vjer.}(T > t) = (1-p)^t = e^{t\ln(1-p)} \approx e^{-pt},$$

jer je $\ln(1-p) \approx -p$ za malo p. Dakle $a \approx p = 0{,}01$ kvarova na sat (tačnije $a = -\ln(1-p) = 0{,}01005$). Ako umjesto po satu provjeravamo sve češće, svakih Δt, sa vjerovatnoćom kvara $a\Delta t$, dobija se tačno $(1-a\Delta t)^{t/\Delta t} \xrightarrow{\Delta t\to 0} e^{-at}$, opet po limesu $(1+x/n)^n \to e^x$.

Očekivanje, varijansa, medijan (knjiga 2.43–2.47). Parcijalnom integracijom (kao u knjizi):

$$\mathrm{E}[T] = \int_0^\infty t\,ae^{-at}\,\mathrm{d}t = \frac{1}{a}, \qquad \mathrm{E}[T^2] = \frac{2}{a^2}, \qquad \mathrm{Var}[T] = \frac{1}{a^2},$$

a medijan iz $1 - e^{-am} = \frac{1}{2}$ iznosi $m = \frac{\ln 2}{a}$. Za $a = 0{,}01/\text{h}$: prosječan vijek je 100 h, a polovina sijalica pregori već do 69,3 h. Medijan je manji od očekivanja jer nekoliko sijalica radi jako dugo (u bilježnici je posljednja pregorjela nakon 985 h). Bilježnica je dala $\mathrm{E}[T] = 100{,}3$ h, $\mathrm{Var}[T] = 10\,252$ h^2 (teorija 10 000; za korak od 1 h tačna vrijednost je $\frac{1-p}{p^2} = 9\,900$) i medijan 69,0 h.

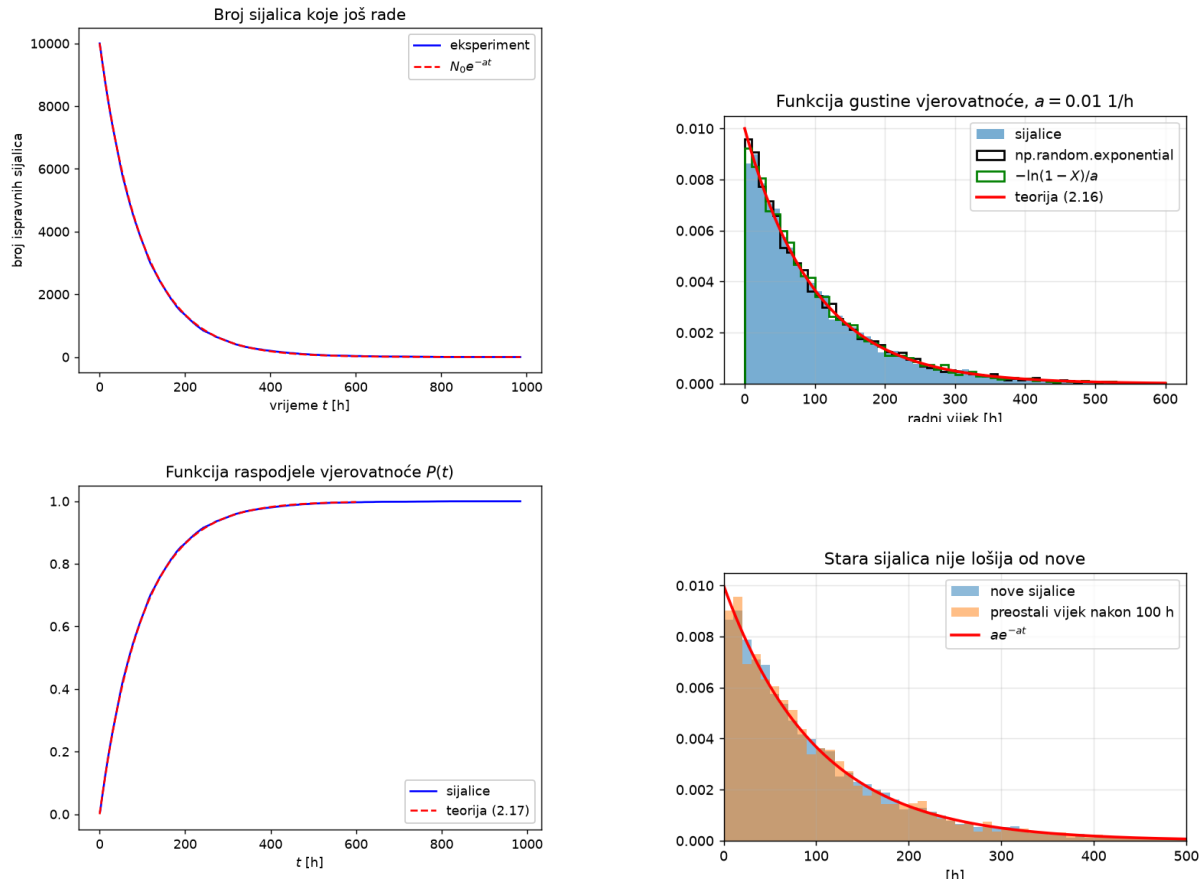
„Nepamćenje“: stara sijalica nije lošija od nove.

$$\text{vjer.}(T > s+t \mid T > s) = \frac{\text{vjer.}(T > s+t)}{\text{vjer.}(T > s)} = \frac{e^{-a(s+t)}}{e^{-as}} = e^{-at} = \text{vjer.}(T > t).$$

Sijalica koja je već radila s sati ima isti preostali vijek kao nova. U bilježnici je za $s = 100$ h prosječan preostali vijek „starih“ sijalica bio 100,9 h, a prosječan vijek novih 100,3 h. Ovo je ujedno i granica modela: uređaji koji se troše (kočnice, baterije) nemaju ovo svojstvo, pa za njih eksponencijalna raspodjela nije dobar model.

Dobijanje iz uniformne raspodjele (Primjer 2.13). Knjiga u Primjeru 2.13 pokazuje da je za uniformnu X na $(0,1)$ promjenljiva $Y = -\frac{1}{\lambda}\ln(1-X)$ eksponencijalna. To je metod inverzne transformacije iz poglavlja 1.5: izjednačimo $P(y) = 1 - e^{-ay}$ sa x i riješimo po y. Provjera:

$$\text{vjer.}(Y \le y) = \text{vjer.}\big(\ln(1-X) \ge -ay\big) = \text{vjer.}\big(X \le 1 - e^{-ay}\big) = 1 - e^{-ay}. \checkmark$$



Slika 4: Sijalice: broj ispravnih sijalica kroz vrijeme, gustina (eksperiment, `np.random.exponential`, Primjer 2.13), funkcija raspodjele i „nepamćenje“.

3 Pregled za ponavljanje

Raspodjela	Eksperiment	Ključni korak izvođenja	$\mathrm{E}[X]$, $\mathrm{Var}[X]$
Uniformna	kockica sa n strana	vjerovatnoća $\propto$ dužina intervala	$\frac{a+b}{2}$, $\frac{(b-a)^2}{12}$
Gaussova	Galtonova daska	$\left[\cos\frac{u}{\sqrt{R}}\right]^R \to e^{-u^2/2}$ (CGT)	a, σ^2
Rayleigheva	pikado, $\sqrt{X^2+Y^2}$	integral po krugu, polarne koordinate	$\sigma\sqrt{\pi/2}$, $\frac{4-\pi}{2}\sigma^2$
Eksponencijalna	radni vijek sijalica	$\mathrm{d}N = -aN\,\mathrm{d}t$; ili $(1-p)^t \to e^{-at}$	$\frac{1}{a}$, $\frac{1}{a^2}$

Veze među njima: uniformna je „sirovina“ za sve ostale (metod inverzne transformacije, Primjeri 2.13 i 2.15); Gaussova nastaje sabiranjem mnogo malih nezavisnih uticaja; Rayleigheva je dužina vektora čije su komponente dvije nezavisne Gaussove; eksponencijalna je vrijeme čekanja na događaj koji je u svakom trenutku jednako vjerovatan.